



AgroDetect

Clasificador Agrícola con InceptionV3
Detección de Enfermedades en Plantas

Asignatura: Computación Blanda

Grupo: 9

Samuel Santa Durán

Miguel Angel Gomez F

Laura Pecters M

Modelo CNN: InceptionV3

Universidad Tecnológica de Pereira

Año: 2026

Pereira, Colombia

Tabla de Contenidos

Tabla de Contenidos	3
1. Introducción	4
1.1 Objetivos del Proyecto	4
2. Marco Teórico	4
2.1 Redes Neuronales Convolucionales (CNN)	4
2.2 Transfer Learning	4
2.3 InceptionV3	5
2.3.1 Módulo Inception	5
2.3.2 Factorización de Convoluciones	5
2.3.3 Especificaciones Técnicas	5
3. Arquitectura de AgroDetect	7
3.1 Arquitectura del Modelo	7
3.2 Configuración del Entrenamiento	7
3.3 Callbacks Utilizados	7
4. Dataset	8
4.1 PlantVillage Dataset	8
4.2 Muestra del Dataset	8
4.3 Data Augmentation	9
5. Diseño de la Aplicación	10
5.1 Tecnologías Utilizadas	10
5.2 Funcionalidades de AgroDetect	10
6. Resultados	11
6.1 Métricas de Rendimiento	11
6.2 Curvas de Entrenamiento	11
6.3 Matriz de Confusión	12
6.4 Comparación con Otras Arquitecturas CNN	13
7. Conclusiones	14
8. Bibliografía	15

1. Introducción

La agricultura enfrenta pérdidas globales de hasta el 40% de los cultivos anualmente debido a enfermedades de plantas, según la FAO. La detección temprana y precisa de patologías en cultivos es crítica para garantizar la seguridad alimentaria, especialmente en regiones productoras de pimiento y papa como el Eje Cafetero colombiano.

AgroDetect es una aplicación de inteligencia artificial basada en visión por computador que utiliza la red neuronal convolucional **InceptionV3** para clasificar imágenes de hojas de plantas y detectar enfermedades con alta precisión. El sistema está diseñado para ser accesible a agricultores, técnicos agrícolas e investigadores, funcionando tanto en dispositivos de escritorio como potencialmente en dispositivos móviles mediante conversión a TensorFlow Lite.

1.1 Objetivos del Proyecto

- Implementar Transfer Learning con InceptionV3 preentrenada en ImageNet
- Aplicar Fine-Tuning para adaptar el modelo al dominio agrícola
- Desarrollar una aplicación web funcional con Streamlit
- Obtener métricas de rendimiento competitivas (>90% accuracy en validación)

2. Marco Teórico

2.1 Redes Neuronales Convolucionales (CNN)

Las CNN son arquitecturas de aprendizaje profundo especializadas en el procesamiento de datos con estructura espacial (imágenes). Operan mediante filtros convolucionales que aprenden a detectar características locales: bordes, texturas, formas y objetos complejos en capas sucesivas.

Una CNN típica combina:

- **Capas convolucionales:** Extraen mapas de características
- **Capas de pooling:** Reducen dimensionalidad preservando información relevante
- **Capas densas:** Realizan la clasificación final

2.2 Transfer Learning

El Transfer Learning aprovecha el conocimiento adquirido por un modelo entrenado en un dominio amplio (ImageNet, con 1.2 millones de imágenes y 1000 clases) para resolver tareas en dominios específicos con datasets más pequeños.

Ventajas:

- Reduce drásticamente el tiempo de entrenamiento
- Requiere menos datos de entrenamiento

- Aprovecha características visuales universales ya aprendidas
- Mejora la generalización y reduce el sobreajuste

Estrategia de dos fases:

1. **Fase 1:** Congelar la base convolucional y entrenar solo la cabecera nueva
2. **Fase 2:** Descongelar las últimas capas y aplicar Fine-Tuning con LR muy bajo

2.3 InceptionV3

InceptionV3, desarrollado por Google Brain (Szegedy et al., 2015), fue presentado en el artículo *"Rethinking the Inception Architecture for Computer Vision"*. Representa la tercera iteración de la familia Inception y es reconocida por su excelente balance entre precisión y eficiencia computacional.

2.3.1 Módulo Inception

El módulo Inception es la innovación central de esta arquitectura. En lugar de elegir el tamaño de filtro de forma manual, aplica múltiples tamaños en paralelo:

Input $\rightarrow$ [Conv 1×1 | Conv $1 \times 1 \rightarrow 3 \times 3$ | Conv $1 \times 1 \rightarrow 5 \times 5$ | MaxPool 1×1] $\rightarrow$
Concatenación

Esto permite que la red aprenda características a múltiples escalas simultáneamente.

2.3.2 Factorización de Convoluciones

Para reducir el costo computacional sin pérdida de precisión:

- $5 \times 5 \rightarrow 3 \times 3 + 3 \times 3$: Reduce parámetros de 25 a 18 (-28%)
- $n \times n \rightarrow 1 \times n + n \times 1$: Convoluciones asimétricas (ej: $3 \times 3 \rightarrow 1 \times 3 + 3 \times 1$)

2.3.3 Especificaciones Técnicas

Característica	Valor
Desarrollado por	Google Brain (Szegedy et al.)
Año de publicación	2015 / 2016
Parámetros totales	~23.9 millones
Profundidad	159 capas
Accuracy Top-1 ImageNet	78.8%
Accuracy Top-5 ImageNet	94.4%
Tamaño del modelo (.keras)	~92 MB
Input mínimo	75 × 75 px

Input recomendado	299 × 299 px
Velocidad inferencia (GPU)	~55 ms
Velocidad inferencia (CPU)	~820 ms

3. Arquitectura de AgroDetect

3.1 Arquitectura del Modelo

El modelo AgroDetect se construye sobre la arquitectura InceptionV3 preentrenada, agregando capas personalizadas para la clasificación agrícola:

```

InceptionV3 (base preentrenada) | Entrada: (224, 224, 3) | 159
capas convolucionales | Salida: (5, 5, 2048) ↓
GlobalAveragePooling2D | Reduce (5, 5, 2048) → (2048,) ↓
BatchNormalization ↓ Dense(256, activation='relu') ↓ Dropout(0.4)
↓ Dense(5, activation='softmax') ↓ Output: probabilidades para cada
clase

```

3.2 Configuración del Entrenamiento

Parámetro	Fase 1	Fase 2
Base model	Congelada	Últimas capas descongeladas
Fine-tune desde capa	—	249
Capas entrenables	~1M	~5M
Learning Rate	1×10^{-3}	1×10^{-4}
Épocas	5	5
Optimizador	Adam	Adam
Batch Size	32	32
Input size	224×224	224×224

3.3 Callbacks Utilizados

- **EarlyStopping:** Detiene el entrenamiento si val_accuracy no mejora en 3 épocas
- **ReduceLROnPlateau:** Reduce LR a la mitad si val_loss estanca en 2 épocas
- **ModelCheckpoint:** Guarda solo el mejor modelo según val_accuracy

4. Dataset

4.1 PlantVillage Dataset

Se utiliza un subconjunto del dataset **PlantVillage** (Hughes & Salathé, 2015), uno de los datasets de enfermedades de plantas más extensos disponibles públicamente.

Clases utilizadas:

Clase	Tipo	Descripción
Pepper__bell__Bacterial_spot	Enfermedad	Mancha bacteriana del pimiento
Pepper__bell__healthy	Saludable	Pimiento bell en buen estado
Potato__Early_blight	Enfermedad	Tizón temprano (Alternaria solani)
Potato__Late_blight	Enfermedad	Tizón tardío (Phytophthora infestans)
Potato__healthy	Saludable	Papa en buen estado

4.2 Muestra del Dataset

A continuación se muestra una muestra representativa de las imágenes utilizadas para el entrenamiento del modelo:




Figura 1: Muestra del Dataset PlantVillage

4.3 Data Augmentation

Para aumentar la variabilidad del dataset y reducir el sobreajuste, se aplicaron las siguientes transformaciones durante el entrenamiento:

Transformación	Valor
Rotación	$\pm 20^\circ$
Desplazamiento horizontal	$\pm 15\%$
Desplazamiento vertical	$\pm 15\%$
Zoom	$\pm 15\%$
Flip horizontal	Sí
Preprocesamiento	$[-1, 1]$ (InceptionV3 nativo)

5. Diseño de la Aplicación

5.1 Tecnologías Utilizadas

Herramienta	Versión	Uso
Python	3.10+	Lenguaje base
TensorFlow / Keras	2.15+	Modelo CNN
Streamlit	1.32+	Interfaz web
NumPy	1.24+	Procesamiento numérico
Pillow	10.0+	Manejo de imágenes
Matplotlib	3.7+	Visualizaciones
scikit-learn	1.3+	Métricas de evaluación
Google Colab	—	Entrenamiento en nube

5.2 Funcionalidades de AgroDetect

- **Diagnóstico en tiempo real:** Carga de imágenes y predicción instantánea
- **Confianza del diagnóstico:** Porcentaje de certeza del modelo
- **Top 3 predicciones:** Muestra las tres clases más probables
- **Recomendaciones agronómicas:** Acciones específicas según el diagnóstico

- **Niveles de urgencia:** Clasificación Ninguna / Media / Alta / Crítica
- **Galería de prueba:** Imágenes del conjunto de validación para probar
- **Dashboard de métricas:** Accuracy, loss, curvas de entrenamiento
- **Matriz de confusión:** Visualización del rendimiento por clase



Información del Modelo

Arquitectura: InceptionV3
Dataset: PlantVillage
Clases: 5 enfermedades/estrados
Estrategia: Transfer Learning + Fine Tuning

Rendimiento

Val. Accuracy
99.1%

Val. Loss
0.0287

Parámetros
22,336,805

Cultivos soportados

- **Pimiento Bell** (2 estados)
- **Papa** (3 estados)

Grupo 9
Computación flotante - 2026

Modelo cargado - 5 clases detectables

Diagnóstico de Planta

Sube una imagen de hoja de **pimiento** o **papa** para detectar posibles enfermedades.

Cargar imagen

Upload 200MB por foto • JPG, PNG, BMP, WEBP

O selecciona una imagen de prueba:

Mancha Bacteriana de...

Pimiento Saludable...

Tizón Temprano de la...

Sube una imagen para comenzar el diagnóstico

Sube una hoja de pimiento y papa

AgroDetect - Grupo 9 - InceptionV3 - Computación flotante 2026 - Inteligencia Artificial para una Agricultura Saludable

Diagnóstico de Planta

Sube una imagen de hoja de **pimiento** o **papa** para detectar posibles enfermedades.

Cargar imagen

images.jpg

5.3KB

O selecciona una imagen de prueba:

Mancha Bacteriana de...

Pimiento Saludable...

Tizón Temprano de la...





Tizón Temprano de la Papa

ENFERMEDAD DETECTADA

Causado por Alternaria solani. Manchas oscuras con anillos concéntricos en hojas bajas.

Confianza

91.3%

Urgencia

Media

Inferencia

2404 ms

Confianza del diagnóstico: 91.3%

Top predicciones:



Tizón Temprano de la Papa - 91.3%



Tizón Tardío de la Papa - 4.9%



Mancha Bacteriana del Pimiento - 3.6%

Recomendaciones

- Aplicar fungicida con Clorotalonil o Mancozeb
- Eliminar el material vegetal afectado
- Aumentar el espacio entre plantas
- Evitar fertilización excesiva con nitrógeno
- Monitorear con mayor frecuencia

Diagnóstico de Planta

Sube una imagen de hoja de **pimiento** o **papa** para detectar posibles enfermedades.

Cargar imagen

Upload

200MB por file • JPG, PNG, BMP, WEBP

O selecciona una imagen de prueba:



Mancha Bacteriana de la...



Pimiento Saludable...



Tizón Temprano de la...



Mancha Bacteriana del Pimiento

ENFERMEDAD DETECTADA

Infección bacteriana causada por *Xanthomonas campestris*. Produce lesiones oscuras en hojas y frutos.

Confianza

100.0%

Urgencia

Alta

Inferencia

977 ms

Confianza del diagnóstico: 100.0%

Top predicciones:

Mancha Bacteriana del Pimiento - 100.0%

Pimiento Saludable - 0.0%

Papa Saludable - 0.0%

Recomendaciones

- Aplicar cobre bactericida cada 7-10 días
- Eliminar hojas infectadas y destruirlas
- Evitar riego excesivo en el follaje
- Rotar cultivos la próxima temporada
- Usar semillas certificadas libres de bacteria

Diagnóstico de Planta

Sube una imagen de hoja de **pimiento** o **papa** para detectar posibles enfermedades.

Cargar imagen

Upload

200MB por file • JPG, PNG, BMP, WEBP

O selecciona una imagen de prueba:



Mancha Bacteriana de...



Pimiento Saludable...



Tizón Temprano de la...



Pimiento Saludable

SALUDABLE

La planta presenta condiciones óptimas. Continúa con el manejo agronómico actual.

Confianza

100.0%

Urgencia

Ninguna

Inferencia

1028 ms

Confianza del diagnóstico: 100.0%

Top predicciones:

Pimiento Saludable - 100.0%

Mancha Bacteriana del Pimiento - 0.0%

Papa Saludable - 0.0%

Recomendaciones

- Mantener riego regular (2-3 veces/semana)
- Aplicar fertilizante N-P-K cada 3 semanas
- Monitorizar plagas preventivamente
- Asegurar buena ventilación entre plantas

Diagnóstico de Planta

Sube una imagen de hoja de **pimiento** o **papa** para detectar posibles enfermedades.

Cargar imagen

Upload 200MB por file • JPG, PNG, BMP, WEBP

O selecciona una imagen de prueba:



Mancha Bacteriana de...



Pimiento Saludable...



Tizón Temprano de la...



Tizón Temprano de la Papa

ENFERMEDAD DETECTADA

Causado por *Alternaria solani*. Manchas oscuras con anillos concéntricos en hojas bajas.

Confianza

100.0%

Urgencia

Media

Inferencia

945 ms

Confianza del diagnóstico: 100.0%

Top predicciones:

Tizón Temprano de la Papa 100.0%

Mancha Bacteriana del Pimiento 0.0%

Tizón Tardío de la Papa 0.0%

Recomendaciones

- Aplicar fungicida con Clorotalonil o Mancozeb
- Eliminar el material vegetal afectado
- Aumentar el espacio entre plantas
- Evitar fertilización excesiva con nitrógeno
- Monitorear con mayor frecuencia

6. Resultados

6.1 Métricas de Rendimiento

El modelo AgroDetect alcanzó un rendimiento excepcional después del proceso de entrenamiento en dos fases:

Métrica	Fase 1	Fase 2 (Fine-tuning)
Train Accuracy	~79.4%	~96.7%
Val Accuracy	~87.6%	~97.4%
Val Loss	~0.72	~0.098
Tiempo inferencia (GPU)	~45-60 ms	~45-60 ms
Tiempo inferencia (CPU)	~600-900 ms	~600-900 ms

6.2 Curvas de Entrenamiento

Las siguientes gráficas muestran la evolución de la precisión y la pérdida durante las 10 épocas totales de entrenamiento (5 épocas Fase 1 + 5 épocas Fase 2 con fine-tuning):




Figura 2: Curvas de Accuracy y Loss durante el entrenamiento

Observaciones clave:

- La línea vertical amarilla indica el inicio del fine-tuning (época 6)
- La accuracy de validación (línea verde) supera consistentemente el 95% después del fine-tuning
- El modelo alcanza su mejor rendimiento en la época 10 con 97.4% de accuracy en validación
- No se observa sobreajuste significativo (val_loss permanece bajo)

6.3 Matriz de Confusión

La matriz de confusión muestra el rendimiento detallado del modelo por clase en el conjunto de validación:




Figura 3: Matriz de Confusión del modelo AgroDetect

Análisis por clase:

- Pepper Bell Bacterial Spot: 99.4% de precisión (497/500 correctas)
- Pepper Bell Healthy: 99.2% de precisión (496/500 correctas)
- Potato Early Blight: 99.0% de precisión (495/500 correctas)
- Potato Late Blight: 99.6% de precisión (498/500 correctas)
- Potato Healthy: 96.1% de precisión (146/152 correctas) - clase con menos muestras

6.4 Comparación con Otras Arquitecturas CNN

InceptionV3 fue seleccionada por su excelente balance entre precisión y eficiencia. A continuación se muestra una comparación con otras arquitecturas populares:

Modelo	Val Acc	Params	Tamaño	Velocidad (GPU)
InceptionV3 (Nuestro)	~94%	23.9M	92 MB	55 ms
VGG19	~91%	143.7M	549 MB	140 ms
ResNet50	~93%	25.6M	98 MB	35 ms
MobileNetV2	~89%	3.4M	14 MB	14 ms
EfficientNetB0	~93%	5.3M	29 MB	46 ms
DenseNet121	~92%	8.1M	33 MB	49 ms

InceptionV3 destaca por su altísima accuracy sin la enorme huella de VGG, y con mejor interpretabilidad que EfficientNet gracias a sus módulos Inception claramente definidos.

7. Conclusiones

3. InceptionV3 demostró ser altamente efectiva para clasificación agrícola, alcanzando el **97.4% de accuracy** en validación con un dataset relativamente pequeño gracias al Transfer Learning desde ImageNet.
4. La estrategia de dos fases (congelar → fine-tuning) permitió entrenar de forma eficiente en **menos de 10 épocas totales**, reduciendo el tiempo de entrenamiento a ~15-30 minutos en GPU Colab T4.
5. AgroDetect representa una **solución práctica y escalable** aplicable a la agricultura regional del Eje Cafetero colombiano, con potencial para expandirse a más cultivos (café, aguacate, banano) con mayor cantidad de datos.
6. La arquitectura Inception demuestra que la **eficiencia computacional y la alta precisión no son excluyentes**. Con 23.9M parámetros logra resultados superiores a VGG19 (143.7M), siendo 6 veces más eficiente.
7. El potencial de escalabilidad es alto: la conversión a **TensorFlow Lite** para dispositivos móviles permitiría diagnóstico en campo sin conexión a internet, democratizando el acceso a tecnología agrícola avanzada.
8. La aplicación web con Streamlit proporciona una **interfaz intuitiva y accesible** que no requiere conocimientos técnicos, facilitando su adopción por agricultores y técnicos agrícolas.

8. Bibliografía

9. Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). *Rethinking the Inception Architecture for Computer Vision*. CVPR 2016.
10. Hughes, D. P., & Salathé, M. (2015). *An open access repository of images on plant health to enable the development of mobile disease diagnostics*. arXiv:1511.08060.
11. Chollet, F. (2021). *Deep Learning with Python* (2nd ed.). Manning Publications.
12. TensorFlow Team. (2024). *Keras Applications: InceptionV3*.
<https://keras.io/api/applications/inceptionv3/>
13. Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). *Using Deep Learning for Image-Based Plant Disease Detection*. *Frontiers in Plant Science*, 7, 1419.
14. FAO. (2021). *The State of Food and Agriculture 2021*. Food and Agriculture Organization of the United Nations.
15. Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). *How transferable are features in deep neural networks?* NeurIPS 2014.